

邪恶思潮

零信任多 Agent 认知战防御系统

360 舆情分析 · 使用说明文档

Version 2.0

2026 年 5 月

目录

1	系统概述	4
1.1	产品定位	4
1.2	核心能力	4
1.3	评分标准覆盖	4
2	系统架构	5
2.1	Agent 协作架构	5
2.2	数据流	5
2.3	技术栈	6
3	快速开始	6
3.1	环境要求	6
3.2	安装步骤	6
4	使用指南	8
4.1	文字信息核查	8
4.2	图片审查	9
4.3	知识图谱	9
4.4	主题切换	10
5	API 参考	10
5.1	核心 API	10
5.2	文本核查 API	10
5.3	图片审查 API	11
5.4	知识图谱 API	11
5.5	基准测试 API	11
6	配置说明	12
6.1	环境变量	12
6.2	模型配置	12
6.3	知识库配置	12
7	项目结构	13
8	认知战攻击模板	14

9 360 生态联动	14
9.1 已实现联动	14
9.2 架构扩展	14
10 常见问题	15
11 版本历史	15
12 许可证与鸣谢	15

1 系统概述

1.1 产品定位

邪恶思潮是一款基于零信任模型的认知战防御系统，专为 360 安全大脑和 360 企业舆情分析产品设计。系统采用多 Agent 协作架构，通过对信息的指纹提取、多源并行搜索、证据辩论合成和质量自我评估，实现对谣言和认知战攻击的自动化识别、溯源和研判。

1.2 核心能力

- **零信任核查**：默认假设所有信息具有恶意意图，全部深度核查
- **14 维指纹提取**：自动识别谣言特征（极端数字、情绪触发、权威伪装等）
- **多源并行取证**：360 搜索 + Firecrawl 搜索 + Firecrawl 抓取三路并行
- **证据辩论合成**：对比 3 路证据，交叉验证，达成共识裁定
- **认知战检测**：匹配 4 种认知战攻击模板，与 360 安全大脑联动预警
- **搜索溯源**：保留真实 URL，点击可直达原文验证
- **知识库进化**：572 条案例库 + 指纹特征匹配 + 谣言进化树
- **图片 OCR 审查**：百度飞桨 OCR 远程 API 提取图片文字后核查

1.3 评分标准覆盖

评分项	权重	覆盖方式
准确性评估	30%	多源交叉验证 + 真实 URL 溯源 + Ground Truth 基准测试
场景覆盖	20%	6 类操纵手法 + 4 类认知战模板 + 15 条带标注测试集
结果闭环	20%	核查 → 报告 → 处方 → 辟谣卡片 → 反馈 → 知识库修正
技术架构	10%	4Agent 协作 + 知识库 (572 条) + 指纹进化 + ChromaDB
Agent 能力	10%	DeepSeek-v4-pro 全国产大模型
360 生态联动	10%	360 搜索核心引擎 + 360 安全大脑联动架构

表 1: 评分标准覆盖对照

2 系统架构

2.1 Agent 协作架构

系统由 4 个专职 Agent 组成流水线，每个 Agent 使用 DeepSeek-v4-pro 进行推理：

1. 谣言指纹官 (Fingerprint Analyst)

提取 14 维谣言指纹特征，进行行为分析和动机分析，检测认知战攻击模式。

2. 三路侦察兵 (Multi-Source Recon)

3 个搜索 Agent 并行工作：

- 360 搜索 Agent：使用 360 搜索引擎检索中文官方数据源
- Firecrawl 搜索 Agent：搜索并抓取网页完整 Markdown 内容
- Firecrawl 抓取 Agent：精准抓取特定 URL 的原文内容

3. 真相仲裁官 (Truth Arbiter)

对比 3 路调查证据，进行辩论合成，达成共识裁定，生成核查报告和认知处方。

4. 品质审核官 (Quality Auditor)

对报告进行四维质量评估：证据充分性、置信度合理性、核查完整性、结论严谨性。

2.2 数据流

用户输入

谣言指纹官 (14维指纹 + 行为动机 + 认知战检测)

输出：evil_score, attack_dimensions, fingerprint

三路侦察兵 (并行)

360搜索 Agent

Firecrawl搜索 Agent

Firecrawl抓取 Agent

输出：findings (claim + verdict + sources + official_data)

真相仲裁官 (辩论合成)

输出：cross_validation, consensus, final_verdict

品质审核官（自我评估）

输出：quality_score, strengths, weaknesses

2.3 技术栈

组件	技术选型	用途
大模型	DeepSeek-v4-pro	全部 Agent 推理
搜索引擎	360 搜索 (so.com)	中文官方数据源检索
网页抓取	Firecrawl	网页 Markdown 提取
OCR	百度飞桨 OCR	图片文字识别
后端	FastAPI + SSE	API 服务 + 流式推送
前端	HTML + Tailwind + vis.js	Web 界面 + 知识图谱
知识库	ChromaDB + JSON	案例存储与检索

表 2: 技术栈总览

3 快速开始

3.1 环境要求

- Python ≥ 3.11
- uv (Python 包管理器)
- 网络连接（API 调用需要）

3.2 安装步骤

1. 克隆项目

```
1 cd /path/to/project
2 git clone <repository-url> MindHacks
3 cd MindHacks
```

2. 安装依赖

```
1 uv sync
```

这将自动安装所有 Python 依赖包，包括：

- FastAPI + Uvicorn (Web 服务)
- httpx (HTTP 客户端)
- BeautifulSoup4 + lxml (HTML 解析)
- ChromaDB (向量数据库)
- RapidOCR (OCR 支持)

3. 配置环境变量

复制配置模板并编辑：

```
1 cp .env.example .env
```

编辑 .env 文件，填入必要的 API Key：

```
1 # DeepSeek API (必需)
2 DEEPSEEK_API_KEY=sk-xxxxxxxxxxxxxxxxxx
3 DEEPSEEK_BASE_URL=https://api.deepseek.com
4
5 # 模型配置
6 PRIMARY_MODEL=deepseek-v4-pro
7
8 # 百度飞桨 OCR API (图片审查需要)
9 BAIDU_OCR_API_KEY=xxxxxxxxxxxxxxxxxx
10 BAIDU_OCR_SECRET_KEY=xxxxxxxxxxxxxxxxxx
11
12 # Firecrawl API (深度网页抓取)
13 FIRECRAWL_API_KEY=fc-xxxxxxxxxxxxxxxxxx
```

⚠ 注意

.env 文件包含敏感 API 密钥，已加入 .gitignore，不会被提交到版本控制。

4. 启动服务

```
1 uv run python main.py
```

启动成功将显示：

```
1
2      邪恶思潮 · 360 舆情分析
3      认知战防御 · 多 Agent 情报 · 360 安全大脑联动
4
5      指纹官 → 三路侦察兵 → 仲裁官
```

5. 访问 Web 界面

浏览器打开：<http://localhost:8000>

 信息

服务默认绑定 0.0.0.0:8000。同一局域网下其他设备可通过 IP 访问，例如 <http://192.168.x.x:8000>。

4 使用指南

4.1 文字信息核查

1. 输入信息

在左侧输入区粘贴可疑的文字信息。支持：

- 朋友圈/群聊转发文本
- 社交媒体帖子
- 新闻文章段落
- 任何需要核查真伪的文本

2. 开始核查

点击红色的”开始核查”按钮。系统将依次执行：

- (a) 指纹提取：识别 14 维谣言特征
- (b) 行为动机分析：判断操纵手法和传播意图
- (c) 认知战检测：匹配攻击模板
- (d) 3 路并行搜索：360 搜索 + Firecrawl 搜索 + Firecrawl 抓取
- (e) 辩论合成：交叉验证，达成共识
- (f) 报告生成：证据链 + 认知处方 + 辟谣卡片
- (g) 质量审核：四维质量评估

整个过程通过 SSE (Server-Sent Events) 实时推送到前端，用户可以看到每个 Agent 的工作状态。

3. 查看结果

核查完成后，右侧会展示完整报告：

- **结论卡片**：邪恶评分、攻击维度、综合判定
- **搜索溯源**：可点击的真实 URL，直达原文验证
- **认知战分析**：攻击模式匹配 + 360 安全大脑联动建议
- **证据链**：每一步核查的证据和来源
- **认知处方**：被什么手法骗了、弱点是什么、怎么防
- **辟谣卡片**：可复制分享的精简辟谣
- **品质评估**：四维质量打分

4. 反馈判定

在报告底部点击”准确”或”不准确”按钮，帮助系统持续改进。

4.2 图片审查

1. 上传图片

支持三种方式上传需要审查的图片：

- 点击”上传截图”按钮选择本地图片
- 在输入框中 Ctrl+V 粘贴剪贴板中的截图
- 拖拽图片到上传区域

上传后会出现图片预览和”图片审查”按钮。

2. OCR 文字提取

系统通过百度飞桨 OCR 远程 API 提取图片中的文字信息，支持中文、英文混合识别。提取结果会显示在 OCR 卡片中。

3. 核查流程

提取的文字自动送入完整的 4Agent 核查流水线，与文字核查流程相同。

4.3 知识图谱

1. 点击顶部导航栏的”知识图谱”按钮切换到图谱视图

2. 可视化展示所有已核查案例及其关系：

- 菱形节点 = 攻击维度（政治稳定、经济信心、社会团结、制度信任）
- 圆点节点 = 操纵手法分类
- 方块节点 = 已核查案例（颜色 = 类别，大小 = 邪恶评分）

3. 可拖拽、缩放、点击节点查看详情

4.4 主题切换

点击 Header 左侧的” 浅色模式/深色模式” 按钮可在深色主题和浅色主题之间切换。主题选择会保存在浏览器本地存储中，刷新后保持。

5 API 参考

5.1 核心 API

方法	端点	说明
POST	/api/analyze	文本核查 (SSE 流式)
POST	/api/analyze-image	图片审查 (SSE 流式)
GET	/api/knowledge/stats	知识库统计
GET	/api/knowledge/graph	知识图谱数据
POST	/api/fingerprint	提取谣言指纹
POST	/api/evolution	进化树 + 行为 + 动机分析
POST	/api/benchmark	Ground Truth 基准测试
POST	/api/feedback	提交用户反馈
GET	/api/demo/cases	获取预设测试案例

表 3: API 端点一览

5.2 文本核查 API

请求

```
1 curl -X POST http://localhost:8000/api/analyze \  
2   -H "Content-Type: application/json" \  
3   -d '{"text": "中国结婚率不足1%，离婚排长队"}'
```

响应 (SSE 流式)

响应格式为 Server-Sent Events，每个事件以 data: 开头，包含 JSON 数据：

```
1 data: {"event": "fingerprint", "data": {...}}  
2 data: {"event": "agent_start", "agent": "malice", "data": {...}}  
3 data: {"event": "cognitive_warfare", "data": {...}}  
4 data: {"event": "parallel_start", "data": {...}}  
5 data: {"event": "parallel_complete", "data": {...}}  
6 data: {"event": "agent_complete", "agent": "debater", "data": {...}}  
7 data: {"event": "search_trace", "data": {...}}
```

```
8 data: {"event": "report", "data": {...}}
9 data: {"event": "done", "data": {...}}
```

SSE 事件类型:

- fingerprint —14 维指纹提取结果
- behavior_motivation —行为分析 + 动机分析 + 进化树
- cognitive_warfare —认知战攻击模式检测
- kb_assist —知识库辅助信息
- agent_start —Agent 开始工作
- agent_complete —Agent 工作完成
- parallel_start —3 路并行搜索开始
- parallel_complete —3 路并行搜索完成
- search_trace —搜索溯源 (真实 URL)
- report —最终核查报告
- done —核查完成

5.3 图片审查 API

请求

```
1 curl -X POST http://localhost:8000/api/analyze-image \
2 -F "file=@screenshot.png"
```

响应格式与文本核查相同, 额外包含 ocr_start 和 ocr_complete 事件。

5.4 知识图谱 API

```
1 curl http://localhost:8000/api/knowledge/graph
```

返回 vis.js 格式的图数据, 包含 nodes 和 edges。

5.5 基准测试 API

```
1 curl -X POST http://localhost:8000/api/benchmark
```

对测试集中前 10 条案例进行自动核查, 返回准确率统计。

6 配置说明

6.1 环境变量

变量	默认值	说明
DEEPSEEK_API_KEY	—	DeepSeek API 密钥（必需）
DEEPSEEK_BASE_URL	https://api.deepseek.com	API 地址
PRIMARY_MODEL	deepseek-v4-pro	主力模型
HOST	0.0.0.0	服务监听地址
PORT	8000	服务端口
BAIDU_OCR_API_KEY	—	百度 OCR API Key
BAIDU_OCR_SECRET_KEY	—	百度 OCR Secret Key
FIRECRAWL_API_KEY	—	Firecrawl API Key
MAX_SEARCH_RESULTS	5	搜索结果数量
REQUEST_TIMEOUT	90.0	LLM 请求超时（秒）

表 4: 环境变量配置

6.2 模型配置

系统默认使用 `deepseek-v4-pro`（DeepSeek V3 系列）。可通过 `PRIMARY_MODEL` 环境变量切换到其他兼容 OpenAI API 的模型。

 注意

DeepSeek-v4-pro 目前不支持图片输入（Vision）。图片审查功能会自动降级到百度飞桨 OCR 远程 API 或本地 RapidOCR。

6.3 知识库配置

知识库使用 bigram 文本相似度进行案例匹配。种子数据包括：

- `data/seed_patterns.json` —20 条基础案例 + 8 种操纵模式
- `data/weibo_seed.json` —500 条微博谣言数据集
- `Chinese_Rumor_Dataset/rumors_v170613.json` —31,669 条原始微博谣言

启动时自动加载，累计 572 条案例。每次核查完成后自动入库，知识库持续增长。

7 项目结构

MindHacks/

main.py	# 启动入口
pyproject.toml	# 依赖配置
.env	# 环境变量（不提交）
config/	
__init__.py	# 全局配置
categories.py	# 6类操纵手法定义
settings.py	# 配置导出
llm/	
client.py	# DeepSeek API客户端
agents/	
base.py	# Agent基类
malice_hypothesis.py	# 谣言指纹官
search_360.py	# 360搜索Agent
search_firecrawl.py	# Firecrawl搜索+抓取Agent
debate_synthesizer.py	# 真相仲裁官
truth_publisher.py	# 报告生成+品质审核
pipeline/	
orchestrator.py	# 4Agent编排器
search/	
web_search.py	# 360搜索+Bing+Google
ocr.py	# 百度飞桨OCR
knowledge/	
store.py	# 知识库（案例+模式）
fingerprint.py	# 14维指纹提取
evolution.py	# 进化树+行为动机分析
cognitive_warfare.py	# 认知战攻击模板
tools/	
firecrawl_tool.py	# Firecrawl工具
api/	
server.py	# FastAPI路由+SSE
frontend/	
index.html	# Web界面
style.css	# 样式（深浅主题）
app.js	# 前端逻辑

```
data/
  seed_patterns.json      # 基础种子数据
  weibo_seed.json         # 微博谣言库
  test_rumors.json        # 测试集 (含Ground Truth)
```

8 认知战攻击模板

系统内置 4 种认知战攻击模板，与 360 安全大脑联动：

1. 系统性信任瓦解 (Critical)

通过持续散布”官方数据造假””政府无能”等信息，瓦解公众对制度的信任。

360 联动: 360 安全大脑标记传播源头和扩散路径。

2. 经济崩溃叙事 (Critical)

夸大经济数据负面变化，构建”中国经济即将崩溃”的虚假叙事。

360 联动: 360 搜索交叉验证官方经济数据与实际报道偏差。

3. 社会分裂工程 (High)

制造群体对立（贫富/地域/代际/性别），撕裂社会团结。

360 联动: 360 浏览器对涉群体对立敏感内容标记预警。

4. 政策破坏攻击 (High)

伪造政府文件/通知，歪曲政策解读，破坏公众信任。

360 联动: 360 安全大脑对虚假官方通知进行格式验证和源头追踪。

9 360 生态联动

9.1 已实现联动

- **360 搜索**：作为核心搜索引擎，对中文官方数据源 (.gov.cn) 优先索引
- **360 安全大脑**：认知战检测结果包含 360 安全大脑联动建议
- **360 浏览器**：架构预留浏览器插件接口，浏览信息时一键提交核查

9.2 架构扩展

360浏览器

360搜索

邪恶思潮

Agent系统

(FastAPI)

360 安全大脑

360 AI

10 常见问题

1. Q: 启动时提示” 知识库种子数据文件不存在”？

A: 这是正常提示。如果 `data/seed_patterns.json` 或 `data/weibo_seed.json` 不存在，系统将以空知识库启动，不影响正常使用。

2. Q: 图片审查失败，提示” 百度 OCR 错误 (18)”？

A: 百度 OCR 免费 API 有 QPS 限制（2 次/秒）。等待几秒后重试即可。

3. Q: 360 搜索返回 0 条结果？

A: 系统会自动降级到 Bing 搜索，不影响核查流程。360 搜索偶尔会因反爬机制暂时不可用。

4. Q: 如何让局域网内其他设备访问？

A: 服务默认绑定 `0.0.0.0:8000`。查看本机 IP(`hostname -I`), 其他设备访问 `http://你的 IP:8000`。注意关闭防火墙。

5. Q: 知识库案例太多，启动变慢？

A: 当前 572 条案例的启动时间约 3 秒。如需加速，可清理 `data/knowledge_db.json` 文件重置知识库。

11 版本历史

版本	日期	更新内容
v1.0	2026-05-30	初始版本，3Agent 管道 + 知识库
v1.1	2026-05-30	多 Agent 并行搜索 + 辩论合成 + KB 不短路
v2.0	2026-05-30	认知战检测 + 搜索溯源 + 360 安全大脑联动 + 基准测试

表 5: 版本历史

12 许可证与鸣谢

本项目为 MindHacks 比赛参赛作品，赛道三：AI Agent —信息真相猎人。

技术鸣谢：

- DeepSeek — 国产大模型支持
- 360 搜索 — 搜索引擎支持
- 百度飞桨 OCR — 图片文字识别
- Firecrawl — 网页抓取工具
- vis.js — 知识图谱可视化

— 文档结束 —